

Proyecto Final

Curso Taller de Aprendizaje por Refuerzo (FIng, UdelaR)

Aplicación al Despacho de Energía en Sistemas Eléctricos

Matías Rama

Florencia Roque

26 de agosto de 2025

Resumen

El problema del despacho óptimo en sistemas eléctricos con alta utilización de renovables presenta una complejidad creciente debido a la incertidumbre hidrológica y a la mayor dimensión del espacio de estados. En este trabajo se desarrolla un entorno simplificado del sistema eléctrico uruguayo en *Gymnasium*, incorporando generación eólica, solar, biomasa, térmica e hidráulica. Sobre este entorno se aplicaron tres algoritmos de aprendizaje por refuerzo representativos de distintas familias: Actor-Critic (A2C), Proximal Policy Optimization (PPO) y Q-learning.

Los resultados muestran que, en escenarios deterministas, tanto PPO como Q-learning logran políticas óptimas capaces de evitar costos térmicos, mientras que A2C converge a soluciones sub-óptimas de turbinado máximo. En escenarios estocásticos, PPO y Q-learning alcanzan políticas más robustas que mitigan parcialmente los costos, aunque sin lograr un aprovechamiento hidráulico plenamente eficiente.

Se concluye que los métodos de aprendizaje por refuerzo son una alternativa viable para aproximar políticas de operación bajo incertidumbre, destacándose PPO y Q-learning frente a A2C. Como trabajo futuro se plantea la incorporación de variables climáticas predictivas y la evaluación de algoritmos actor-critic más avanzados.

1. Introducción

La operación de los sistemas eléctricos enfrenta el desafío de decidir, semana a semana, cómo utilizar de manera óptima los diferentes recursos de generación para cubrir la demanda al menor costo posible y con seguridad de suministro. En particular, en países como Uruguay, la dependencia de la hidroelectricidad introduce una fuerte incertidumbre hidrológica, ya que los aportes de agua a los embalses son variables en cada paso de tiempo. A esto se suma la creciente incorporación de fuentes renovables variables (eólica y solar), que aumentan la complejidad del sistema y hacen que las decisiones de operación deban considerar múltiples fuentes con dinámicas muy distintas. Además, la transición energética plantea la integración de nuevas tecnologías como el hidrógeno verde, que representan tanto oportunidades como desafíos para la planificación y la operación en el mediano plazo (1).

Tradicionalmente, este problema práctico, conocido como despacho óptimo, se ha abordado con técnicas de optimización matemática. Una de las más utilizadas ha sido la Programación Dinámica Estocástica (PDE), que formula la operación como una secuencia de decisiones en múltiples etapas y aplica la recursión de Bellman para minimizar el costo esperado en el horizonte de planificación (2). Sin embargo, la incorporación masiva de renovables incrementó la dimensionalidad del problema, haciendo impracticable la resolución exacta. Para superar esta limitación, Pereira y colaboradores propusieron la Programación Dinámica Estocástica Dual (SDDP), que aproxima la función de valor futuro mediante hiperplanos obtenidos en simulaciones forward-backward (3). Esta metodología fue implementada en el software MOP, desarrollado en UTE¹, constituyendo la primera aplicación industrial de optimización del sistema eléctrico uruguayo mediante SDDP (5). Otro software utilizado en Uruguay es SimSEE, desarrollado en la Universidad de la República, ampliamente aplicado para estudios de planificación y análisis operativo (6).

Un aspecto central en estos enfoques es el modelado de la hidrología. Tanto en MOP como en este trabajo, los aportes a los embalses se representan mediante cadenas de Markov, que permiten capturar la naturaleza estocástica de las transiciones hidrológicas semana a semana (7). Este esquema encuadra naturalmente el problema en un Proceso de Decisión de Markov (MDP), en el cual los estados están dados por el volumen del embalse, la condición hidrológica y el paso temporal; las acciones corresponden a las decisiones de turbinado; las transiciones se definen por el balance hídrico y la cadena de Markov; y la recompensa refleja el costo térmico evitado.

Sobre esta base, han surgido metodologías modernas basadas en Aprendizaje por Refuerzo (RL), que formulan el problema precisamente como un MDP y permiten aprender políticas de operación óptimas a partir de la interacción con el entorno, sin necesidad de conocer de forma explícita todas las probabilidades de transición (8). Una revisión reciente destaca el potencial de estas técnicas para mejorar la eficiencia, confiabilidad y sostenibilidad de los sistemas energéticos (9), mostrando que RL constituye una alternativa prometedora frente a los métodos clásicos.

En este trabajo se propone aplicar y comparar distintos algoritmos de aprendizaje por refuerzo, tanto tabulares como basados en gradiente de políticas, sobre un modelo simplificado del sistema eléctrico uruguayo, con el objetivo de evaluar su capacidad para aproximar políticas de operación bajo incertidumbre hidrológica.

2. Abordaje Propuesto para la Resolución del Problema de Operación

En esta sección se describe el modelo matemático del sistema eléctrico uruguayo contemplado en el trabajo actual, también se presenta la metodología de aprendizaje por refuerzo utilizada para la resolución.

¹MOP: Modelo de operación de sistemas eléctricos de generación desarrollado en la Gerencia de Planificación del Abastecimiento de UTE, de código abierto y programado en Java (4).

2.1. Modelado Propuesto del Sistema Eléctrico

Con el objetivo de aplicar y comparar métodos de aprendizaje por refuerzo, se formula un modelo simplificado del sistema eléctrico uruguayo. El sistema incluye generación eólica, solar, biomasa, térmica (de bajo y alto costo), una central hidráulica con embalse y aportes aleatorios, demanda y exportación.

La hidráulica se modela como una única central denominada *Claire*, equivalente a la combinación de Bonete, Baygorria, Palmar y Salto Grande (la cual se divide a la mitad por ser compartida con Argentina). Se considera un coeficiente energético constante k_{Claire} y una dinámica de volumen del embalse dada por una ecuación de balance hídrico:

$$v_{t+1} = \min \left(v_t + a_t - \frac{P_t}{k_{Claire}} \Delta t, v^{max} \right). \quad (1)$$

El balance de potencia semanal se expresa como:

$$P_{eol} + P_{sol} + P_{bio} + P_{term_bajo} + P_{term_caro} + k_{Claire} Q_t^{tur} = D_t + P_{exp}^t. \quad (2)$$

La variable hidrológica v_{hidro} representa el estado de sequía o humedad y se modela como una cadena de Markov no homogénea, con una matriz de transición distinta por cada semana del año. A partir de datos históricos de aportes se construyen 52 matrices de transición de 5×5 y se discretizan los aportes en quintiles.

La dinámica de los estados es:

- v_{Claire}^{t+1} : volumen del embalse (balance hídrico (1)).
- v_{hidro}^{t+1} : muestreado con la matriz de transición de Markov.
- $t \leftarrow t + 1$.

La generación renovable (eólica, solar, biomasa) y la demanda se toman determinísticas a partir de un promedio semanal y de escenarios históricos (MOP). Los aportes hidrológicos se sortean de los datos históricos discretizados. Para representar mejor la operación real, la demanda se ajustó por un factor de 1.2, ya que el promediar eso suaviza los máximos y mínimos.

Como se puede ver en la sección (2.2.1), los valores de cuánta energía aporta la central hidráulica para cubrir la demanda de la semana t son dados como acciones del agente, luego quedan determinadas las energías térmicas. La energía que se exporta se considera como la energía que sobra con respecto a la demanda, es decir, que queda determinada una vez que se obtienen los valores de todas las demás energías; se utiliza para evitar infactibilidades matemáticas en la ecuación del balance (2).

Con este modelo simplificado se obtienen las transiciones y recompensas que alimentan al agente de aprendizaje por refuerzo.

2.2. Aplicación de Aprendizaje por Refuerzo al Problema de Operación

2.2.1. Metodología

El problema se modeló como un entorno en `Gymnasium`, definiendo de manera explícita los espacios de estados, acciones y recompensas. El estado incluye tres variables: el volumen del embalse, el estado hidrológico y el paso temporal. El volumen se representa de manera continua o discreta según el algoritmo utilizado. La variable hidrológica se modela con $N_{\text{hidro}} = 5$ estados, obtenidos a partir de la clasificación histórica de aportes en cinco categorías discretas que reflejan condiciones de sequía, normalidad y abundancia. Finalmente, el tiempo se discretizó en semanas dentro de un horizonte de 104 pasos, correspondiente a dos años.

Las acciones corresponden a la decisión de cuánta agua turbinar en cada semana. Para los algoritmos con espacio de acción continuo (A2C y PPO) se representó como una fracción en $[0, 1]$ del volumen máximo turbinable. En cambio, para Q-learning se optó por discretizar en 40 niveles posibles, lo que permite explorar políticas tabulares sin requerir aproximación funcional. La recompensa se definió como el opuesto del costo térmico incurrido en la semana, incluyendo en el caso de PPO un término adicional por vertimiento, de modo de penalizar la pérdida de agua que podría haber generado energía.

2.2.2. Algoritmos y Configuración de Entrenamiento

Se implementaron tres algoritmos representativos de distintas familias. El método Actor-Critic (A2C) se utilizó como ejemplo de policy gradient con función de valor, aprovechando la librería `Stable Baselines3`. El algoritmo Proximal Policy Optimization (PPO) se configuró en su variante recurrente (`MlpLstmPolicy`), lo que le permite al agente explotar dependencias temporales en la serie hidrológica y distinguir situaciones de abundancia o sequía a lo largo de la trayectoria. Finalmente, Q-learning se empleó como método tabular, representando un enfoque value-based clásico.

El número de episodios de entrenamiento se fijó en 2000 para los métodos basados en gradiente, lo que resultó suficiente para observar convergencia estable en los experimentos preliminares. En el caso de Q-learning, debido a la mayor exploración requerida por la discretización, se emplearon 10000 episodios. La Tabla 1 resume los hiperparámetros principales utilizados en cada algoritmo.

Tabla 1: Hiperparámetros principales de los algoritmos implementados

Algoritmo	Política / Red	Hiperparámetros clave	Episodios
A2C	MlpPolicy	$lr = 5 \cdot 10^{-4}$; $n_{envs} = 8$; $n_{steps} = 12$	2000
PPO	MlpLstmPolicy	$\gamma = 0.999$; $lr = 3 \cdot 10^{-4}$; $ent_coef = 0.005$; $n_{steps} = 52$	2000
Q-learning	Tabla Q (3120 $\times$ 40)	$lr = 0.001$; $\gamma = 0.99$; $\epsilon = 0.01$	10000

2.2.3. Parámetros del Sistema Energético

La instancia del sistema se basó en un modelo simplificado de la matriz eléctrica uruguaya. La Tabla 2 muestra los parámetros adoptados para cada tecnología. Estos valores fueron

tomados de datos históricos y ajustados de forma de mantener la consistencia con un horizonte semanal.

Tabla 2: Parámetros principales del sistema energético considerado

Parámetro	Valor	Unidad
$T_{\text{máx}}$	103	semanas
N_{hidro}	5	-
$P_{\text{Claire}}^{\text{máx}}$	1541	MW
$P_{\text{solar}}^{\text{máx}}$	254	MW
$P_{\text{eólico}}^{\text{máx}}$	1584.7	MW
$P_{\text{biomasa}}^{\text{máx}}$	487.3	MW
$P_{\text{térmica bajo}}^{\text{máx}}$	500	MW
$P_{\text{térmica alto}}^{\text{máx}}$	5000	MW
$V_{\text{Claire}}^{\text{máx}}$	60000	hm ³
$C_{\text{térmico bajo}}$	100	USD/MWh
$C_{\text{térmico alto}}$	300	USD/MWh

La central de bajo costo es la primera que se usa en caso de no cubrir la demanda residual con la energía hidráulica, pero tiene una potencia baja de 500 MW. Si con esta última no se llega a cubrir la demanda residual se usa la central térmica de alto costo que tiene una potencia de 5000 MW. Con los datos de demanda usados, esta potencia de centrales térmicas da de sobra para abastecer la demanda en todo momento.

3. Resultados

3.1. Actor-Critic

La figura (1) muestra la convergencia durante el entrenamiento de la política utilizando Actor-Critic con aportes estocásticos, en donde la línea naranja muestra el promedio de la recompensa acumulada en los 100 episodios anteriores.

Se ve claramente como la recompensa acumulada aumenta con el entrenamiento hasta el episodio 500 en donde parecería quedar estable (converge en una recompensa cercana a -550 MUSD).

Para la figura (1) tiene sentido analizar el promedio dado que la recompensa acumulada de cada episodio tiene una gran varianza debido a que hay escenarios más lluviosos, secos, con más o menos generación renovable (eólico y solar) lo que incide directamente en la cantidad de energía térmica que se debe utilizar.

En la figura (2) se puede ver el gráfico que muestra la acción en promedio de 100 escenarios evaluados, utilizando la política aprendida en el entrenamiento. El agente siempre toma acción 1, aprende que turbinando lo máximo posible logra la mayor recompensa. No aprende a gestionar la energía hidráulica. Esto se puede apreciar también en la figura (3) la cual muestra la demanda, la energía hidráulica, la energía renovable (que es la suma de la generación eólica, solar y biomasa) y la energía térmica (cara y barata) utilizada en cada paso semanal para




Figura 1: Entrenamiento Actor-Critic.

una crónica concreta. También en esta gráfica (pero en otra escala) están el volumen del lago y sus aportes.




Figura 2: Acciones del Actor-Critic.




Figura 3: Crónica 11 Actor-Critic.

3.2. Proximal Policy Optimization

3.2.1. Aportes Determinísticos

Al usar aportes determinísticos con el algoritmo PPO es esperable que el agente aprenda a gestionar el agua de manera de no incurrir en ningún costo térmico, ya que no hay aleatoriedad en el parque eléctrico.




Figura 4: Recompensa entrenamiento PPO con aportes determinísticos.

En la figura (4) se observa que la recompensa del entrenamiento converge a cero, es decir, no se incurre en ningún costo térmico. Las recompensas tienen poca varianza, producto de los aportes determinísticos.




Figura 5: Crónica de evaluación PPO con aportes determinísticos.

En la evaluación de una crónica, figura (5), se puede apreciar cómo el agente es capaz de gestionar el volumen del embalse de manera de siempre satisfacer la demanda residual solo con energía hidráulica, ya que sabe la cantidad de aportes que va a tener en cada semana y por tanto la política óptima.

3.2.2. Aportes Estocásticos

En el caso de tener aportes estocásticos, al agente le resulta más complejo determinar la política óptima al no saber en qué situación se encuentra en cada paso de tiempo, por lo tanto es esperable que se usen las centrales térmicas.




Figura 6: Recompensa entrenamiento PPO con aportes estocásticos.

En este caso el agente sí incurre en costo térmico como es esperable y se puede ver que el reward converge a -250 MUSD en el entrenamiento, ver figura (6). También se observa que la varianza es mucho más grande en las recompensas porque hay aleatoriedad.

Al realizar la evaluación de una crónica (figura (7)) se puede apreciar que efectivamente se usa energía térmica tanto de la central de bajo costo como de la de alto costo para satisfacer la demanda residual. Sin embargo, cabe destacar que hay un intento de guardar agua, es decir, incurrir en costo térmico bajo para evitar el costo térmico alto en un futuro, pasada la semana 20.




Figura 7: Crónica de evaluación PPO con aportes estocásticos.

3.3. Q-Learning

3.3.1. Aportes Determinísticos

La gráfica en la figura (8) muestra el entrenamiento de Q-learning con aportes determinísticos:




Figura 8: Entrenamiento Q-Learning determinístico.

De la manera que Q-learning fue implementado requiere un entrenamiento con muchos episodios, su aprendizaje se estancó aproximadamente a los 8000 episodios y su reward acumulado fue muy cercano a 0. Es decir, llegó casi al óptimo, ya que no hay recompensas positivas.

En la figura (9) se puede observar un gráfico de la demanda y generación junto al volumen del lago y los aportes a este.




Figura 9: Cronica 11 Q-Learning con aportes determinísticos.

Ocurre lo ideal, dado que ya tiene un futuro conocido de demanda y aportes, optimiza el uso del agua al punto de no requerir emplear energía térmica.

3.3.2. Aportes Estocásticos

En la figura (10) se muestra el entrenamiento con Q-learning con aportes estocásticos.




Figura 10: Entrenamiento Q-Learning con aportes estocásticos.

A diferencia del caso con aportes determinísticos, ahora hay semanas más secas o lluviosas, y el agente no sabe a qué semana se enfrenta en cada episodio, lo que hace que no siempre tome las mejores decisiones. A pesar de esto, igual tiene un buen rendimiento teniendo una recompensa acumulada de aproximadamente -300 MUSD.

En la figura (11) se muestra cómo se abastece la demanda en un escenario concreto (junto al volumen del lago y a los aportes).




Figura 11: Crónica 11 Q-Learning con aportes estocásticos.

En las primeras semanas se nota que usa mucha agua, pero luego tiende a no prender térmico, lo cual denota un buen desempeño del agente en general.

Es importante tener en cuenta que el desempeño del agente en las primeras semanas está fuertemente condicionado por la situación inicial del embalse.

4. Conclusiones y Trabajos Futuros

En el escenario con aportes hidrológicos determinísticos, el agente converge de manera consistente hacia una política cercana a la óptima esperada, validando que el modelo planteado es capaz de capturar la dinámica esencial del problema.

En el escenario estocástico, en cambio, la política a la cual converge el agente no resulta óptima para cada trayectoria individual, ya que el agente carece de información sobre la hidrología futura. En este contexto, aprende a seleccionar la mejor acción en promedio. Este comportamiento es consistente con la teoría de procesos de decisión de Markov, donde bajo la misma condición de estado la mejor acción no siempre coincide debido a la incertidumbre de la transición estocástica. Incorporar variables adicionales de predicción meteorológica (por ejemplo, indicadores de fenómenos como El Niño/La Niña) podría mejorar la calidad de las decisiones, al proveer señales que reduzcan la incertidumbre sobre los aportes futuros.

Respecto a los algoritmos evaluados, el método A2C mostró un desempeño pobre, convergiendo a políticas miopes que tienden a turbinar en exceso. Esto puede atribuirse tanto a la red neuronal por defecto utilizada como a la menor estabilidad de este método frente a PPO. En contraposición, PPO con una arquitectura recurrente (LSTM) logró políticas más estables y consistentes, mientras que Q-learning permitió obtener políticas razonables en el espacio discretizado, aunque con limitaciones de escalabilidad frente al espacio continuo. La diferencia de calidad de solución obtenida entre PPO y Q-learning se puede deber a la discretización que se aplica para entrenar con el método tabular y a que la red LSTM capture mejor la correlación temporal.

Entre las posibles líneas de extensión del presente trabajo se destaca, en primer lugar, la incorporación de variables de predicción climática en el espacio de estados, con el propósito de disminuir la incertidumbre asociada a los aportes hidrológicos. Asimismo, resulta de interés contrastar los resultados alcanzados mediante aprendizaje por refuerzo con los obtenidos a partir de modelos de optimización como MOP, lo cual permitiría cuantificar de forma objetiva las ventajas y limitaciones del enfoque propuesto. Finalmente, se considera pertinente la implementación de una versión reducida en MOP y su posterior comparación con el sistema real, con el fin de validar y enriquecer los resultados en escenarios más próximos a la práctica.

Referencias

- [1] B. Bouzas, E. Teliz, and V. Díaz, “Green hydrogen production in uruguay: a techno-economic approach,” *International Journal of Chemical Reactor Engineering*, vol. 22, no. 7, pp. 783–795, 2024.
- [2] M. P. Cristobal, L. F. Escudero, and J. F. Monge, “On stochastic dynamic programming for solving large-scale planning problems under uncertainty,” *Computers & Operations Research*, vol. 36, no. 8, pp. 2418–2428, 2009.
- [3] M. V. Pereira and L. M. Pinto, “Multi-stage stochastic optimization applied to energy planning,” *Mathematical programming*, vol. 52, no. 1, pp. 359–375, 1991.
- [4] UTE, “MOP,” <https://gitlab.com/utepladmm/MOP>, 2024, [Online].
- [5] J. Mauriz, R. G. Porteiro, and M. Ibarburu, “Mop: first industrial application of stochastic dual dynamic programming for optimization of the uruguayan power system,” in *2024 IEEE URUCON*. IEEE, 2024, pp. 1–5.
- [6] G. Casaravilla, R. Chaer, and P. Alfaro, “Simsee: Simulador de sistemas de energía eléctrica,” *Proyecto PDT 47/12. Technical Report 7, Universidad de la República (Uruguay). Facultad de Ingeniería. Instituto de Ingeniería Eléctrica, Number 7-Dec, Tech. Rep.*, 2008.
- [7] C. Haan, D. Allen, and J. Street, “A markov chain model of daily rainfall,” *Water Resources Research*, vol. 12, no. 3, pp. 443–449, 1976.
- [8] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. Cambridge, MA: MIT Press, 2018.
- [9] S. Stavrev and D. Ginchev, “Reinforcement learning techniques in optimizing energy systems,” *Electronics*, vol. 13, no. 8, p. 1459, 2024.