

Proyecto Final - Taller de Aprendizaje por Refuerzo

Aplicación al Despacho de Energía en Sistemas Eléctricos

Matías Rama

mrma@ute.com.uy

Florencia Roque

froque@ute.com.uy

Facultad de Ingeniería
Universidad de la República

September 1, 2025

Agenda

1. Motivación
2. Diagrama del Sistema de Aprendizaje
3. Entorno Sistema Eléctrico
4. Datos
5. Estados, Acciones, Recompensas
6. Dinámica de Estados
7. Algoritmos Probados
8. Entrenamiento
9. Resultados en Entrenamiento
10. Despacho de una Crónica de Ejemplo
11. Evaluación con Aportes Determinísticos
12. Conclusiones

- ▶ Aplicación de RL al problema de operación óptima en sistemas eléctricos.
- ▶ Complejidad creciente debido a:
 - ▷ Incertidumbre hidrológica.
 - ▷ Mayor dimensión del problema por la incorporación masiva de renovables no convencionales.
- ▶ Objetivo: hallar el despacho óptimo hidráulico con paso semanal en un horizonte de dos años.

Diagrama del Sistema de Aprendizaje




Figure: Diagrama de bloques de agente-entorno.

Entorno Sistema Eléctrico




Figure: Diagrama de bloques del modelado del sistema eléctrico.

- ▶ Matriz de datos de aportes con hidrologías discretas (52×114).
- ▶ Matriz de datos de aportes correspondiente con la anterior pero con valores continuos (52×114).
- ▶ 52 matrices de transición de Markov de 5×5 cada una.
- ▶ Tira de datos determinísticos para 2 años (104×1):
 - ▷ Energías eólico.
 - ▷ Energías solar.
 - ▷ Energías biomasa.
 - ▷ Demandas.

Estados, Acciones, Recompensas

► Estados:

- ▷ Semana (t).
- ▷ Volumen del embalse (v_t).
- ▷ Hidrología ($h_t \in \{0, 1, 2, 3, 4\}$).

► Acciones:

- ▷ a_t .
- ▷ Fracción del turbinado máximo.

► Recompensas:

- ▷ r_t .
- ▷ El opuesto del costo térmico.
- ▷ Para el caso de un algoritmo particular se agregó un término de penalización por vertimiento.

- ▶ $t \leftarrow t + 1$
- ▶ $v_{t+1} = v_t + \text{aportes}_t - v_{turb}$
 - ▷ v_{turb} se obtiene a partir de la acción del agente RL.
 - ▷ aportes_t se sortea de todos los aportes correspondientes a esa semana y a la hidrología actual.
- ▶ La hidrología siguiente h_{t+1} se muestrea con la matriz de transición de Markov correspondiente a la semana $t\%52$.
 - ▷ Porque hay 52 matrices, una por cada semana del año y como el horizonte es de dos años es necesario tomar módulo para que no haya problemas de rango.


- ▶ A2C (Actor-Critic):
 - ▷ Política: MlpPolicy.
 - ▷ $lr = 5 \times 10^{-4}$.
 - ▷ $\gamma = 0.99$.
- ▶ PPO (Proximal Policy Optimization):
 - ▷ Política: MlpLstmPolicy.
 - ▷ $lr = 3 \times 10^{-4}$.
 - ▷ $\gamma = 0.999$.
- ▶ Q-Learning:
 - ▷ Política: Tabla Q de tamaño 3120×40 .
 - ▷ $lr = 0.001$.
 - ▷ $\gamma = 0.99$.

- ▶ Para llegar a un resultado se utilizaron los 3 algoritmos definidos anteriormente.
- ▶ Horizonte de entrenamiento: 2 años.
- ▶ 2000 episodios para A2C y PPO.
- ▶ 10000 episodios para Q-learning.
- ▶ Dos alternativas para cada algoritmo: aportes determinísticos y estocásticos.


Resultados en Entrenamiento

Caso con aportes estocásticos:


- ▶ A2C converge a aproximadamente -500 MUSD.
- ▶ PPO a aprox. -250 MUSD.
- ▶ Q-Learning a aprox. -300 MUSD.



A2C



PPO



Q-Learning

- ▶ En el caso con aportes determinísticos, A2C tiene el mismo comportamiento subóptimo pero PPO y Q-Learning convergen a 0.

Evaluación: A2C

- ▶ A2C dio siempre acción 1, es decir que turbinando siempre lo máximo posible logra la mayor recompensa.
- ▶ No aprende a gestionar la energía hidráulica, a guardar en momentos donde pueden aproximarse sequías con altos valores de demanda.




Figure: Crónica 11 de A2C estocástico.

Evaluación: PPO

- PPO muestra que hay momentos donde decide prender térmico barato para guardar agua que usa en las siguientes semanas, ya que el agente aprendió que en ese estado en las semanas siguientes hay más probabilidad de bajos aportes y alta demanda.
- Se ve cómo en los picos de la demanda utiliza solo energía renovable no convencional e hidráulica, logrando reducir el uso de los térmicos.




Figure: Crónica 11 de PPO estocástico.

Evaluación: Q-Learning

- Tiene un buen rendimiento, teniendo en cuenta que el desempeño del agente en las primeras semanas está fuertemente condicionado por la situación inicial del embalse.




Figure: Crónica 11 de Q-Learning estocástico.

Evaluación con Aportes Determinísticos

- El agente converge de manera consistente hacia una política cercana a la óptima esperada, la recompensa converge a 0 en entrenamiento (figura (a)).
- En la figura (b) se puede apreciar que no se prende en ningún momento ninguno de los térmicos.




Figure: (a) Reward en train con aportes determinísticos.




Figure: (b) Crónica 11 de PPO con aportes determinísticos.

Conclusiones

- ▶ El agente aprende una política que tiene sentido con la operación real para PPO y Q-learning.
- ▶ A2C mostró un mal desempeño, convergiendo a una política que turbinaba en exceso, se pretende investigar con otros hiperparámetros que ayuden a mejorar este resultado.
- ▶ PPO con una arquitectura de red recurrente LSTM logró políticas más estables y consistentes.
- ▶ Q-Learning dio buenos resultados teniendo en cuenta la discretización del espacio de estados y acciones. La diferencia en la calidad de las soluciones obtenidas con PPO y Q-learning puede deberse a la discretización del método tabular y que la red LSTM captura mejor la correlación temporal.
- ▶ Trabajos futuros:
 - ▷ Incorporar indicadores de fenómenos meteorológicos como El Niño/La Niña en el espacio de estados.
 - ▷ Contrastar resultados obtenidos con los de MOP y posterior implementación dentro del mismo.

Gracias